Parte 1 – Registro do Experimento

Definição das categorias

· Perfil Liderança: imagens de homens vestindo terno.

· Perfil Operacional: imagens de mulheres com roupas informais.

Alimentação do dataset (enviesado)

Foram capturadas 20 imagens para cada classe, totalizando 40 amostras de treinamento. O viés foi intencionalmente inserido:

· Classe “Liderança”: somente homens de terno.

· Classe “Operacional”: somente mulheres com roupas casuais.

Teste de inferência

Após o treinamento, o modelo foi testado com imagens de:

1. Um homem vestindo camiseta azul (sem terno).

2. Uma mulher vestindo terno e gravata.

Registro do erro (falso positivo/negativo)

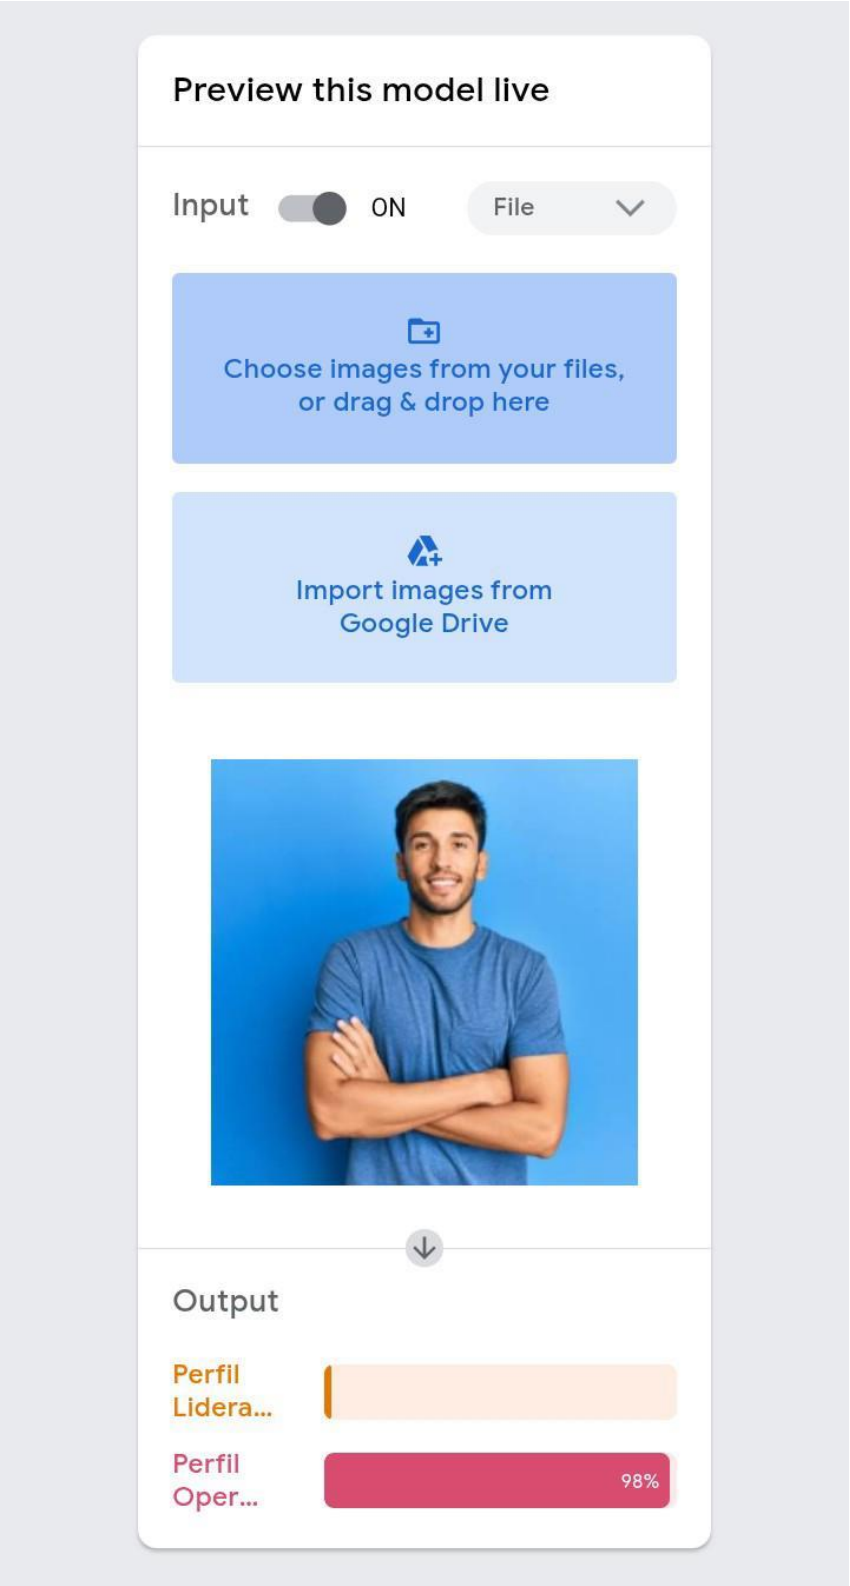

O modelo classifica o homem sem terno como Perfil Operacional com altíssima confiança (98%), mesmo tendo sido treinado exclusivamente com mulheres para esta classe. Ele ignora o gênero e associa a ausência do terno à classe operacional.

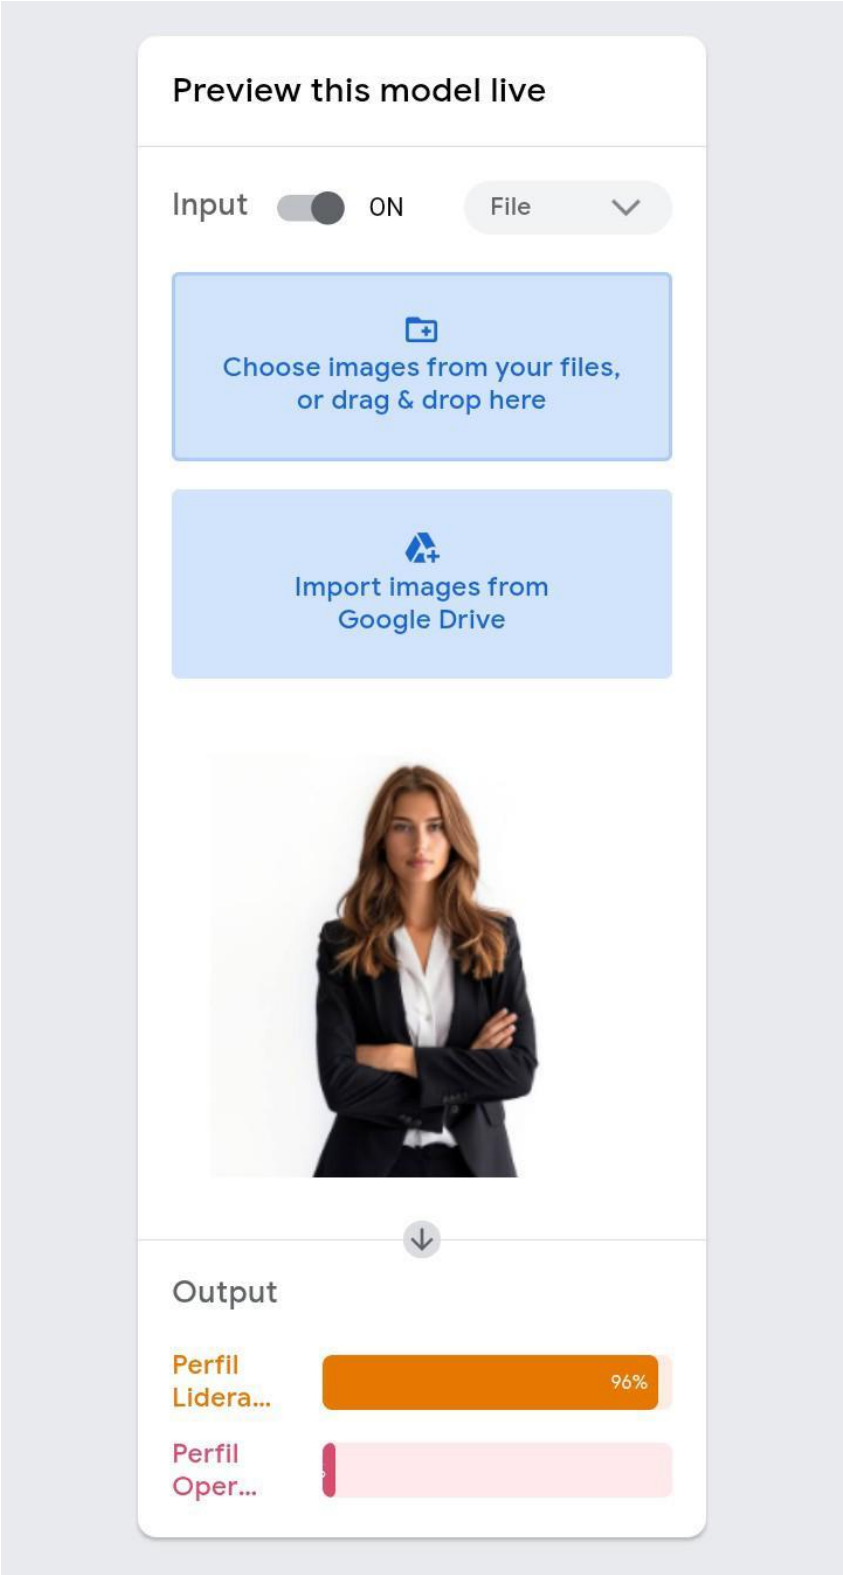

O modelo classifica a mulher de terno como Perfil Liderança com 96% de confiança, embora nunca tenha visto uma mulher durante o treinamento dessa classe. O algoritmo priorizou a presença do terno como característica determinante, sobrepondo-se ao gênero.

Interpretação do erro

Este resultado é paradoxal e extremamente didático:

· O modelo não aprendeu “gênero” como característica principal, como se poderia esperar de um dataset enviesado.

· Em vez disso, ele aprendeu “terno = liderança” e “sem terno = operacional”, independentemente do gênero da pessoa testada.

· A falha de generalização persiste: uma mulher de terno é liderança; um homem sem terno é operacional. O algoritmo reproduz um viés de vestuário e status, não necessariamente de gênero.

Esse achado demonstra que vieses podem se manifestar de formas imprevisíveis, e que o modelo não “entende” conceitos humanos como gênero – ele apenas detecta correlações superficiais nos dados.

Parte 2 – Memorial de Impacto e Ética

Mecanismo do Viés

A seleção restrita de dados corrompe a lógica do algoritmo ao supergeneralizar características superficiais (o terno, o fundo do escritório, a roupa casual) como se fossem determinantes para o perfil profissional. O modelo não compreende que uma mulher pode usar terno ou que um homem pode vestir roupas informais. Ele reduz a realidade a um conjunto limitado de padrões visuais, gerando uma visão distorcida onde a vestimenta define a função, independentemente da identidade ou qualificação da pessoa.

Consequência Social

Um indivíduo marginalizado por esse sistema sente-se injustiçado e reduzido a uma aparência. Um homem de camiseta classificado como “operacional” experimenta frustração ao ver sua competência ignorada por uma ferramenta que julga pela roupa. Uma mulher de terno que recebe o rótulo “liderança” pode

até sentir-se validada, mas o problema persiste: o modelo não a reconhece por mérito, e sim por um padrão arbitrário que privilegia certos códigos estéticos. Em processos seletivos automatizados, essa lógica exclui profissionais competentes que fogem do estereótipo visual, aprofundando desigualdades sociais.

Ação Mitigadora (Human-in-the-loop)

Implementa-se uma curadoria colaborativa: antes do treinamento final, um comitê diverso de colaboradores revisa cada lote de imagens por meio de uma ferramenta simples (ex: planilha de validação). O sistema alerta quando uma classe apresenta menos de 30% de diversidade de vestuário, fundo ou composição demográfica. O revisor humano pode rejeitar amostras ou solicitar novas capturas para balancear o dataset. Adicionalmente, um segundo humano testa o modelo com contraexemplos (homem sem terno, mulher de terno) antes da implantação. Essa intervenção garante que a curadoria reflita princípios éticos antes da fase de treinamento.